

Tema Învățare Automată

Partea 2

Scopul general este de a dezvolta o înțelegere practică a tranziției de la metodele clasice la cele moderne și de a explora impactul inovațiilor recente din învățarea automată asupra problemelor reale de clasificare a imaginilor.

FASHION-MNIST

1. MLP pe atributele extrase în etapa 1

Am selectat exact 64 de atribute:

Numărul de atribute extrase: 64

Arhitectura rețelei:

1. Numărul de straturi și numărul de neuroni pe fiecare strat:

- **Stratul 1:** Fully Connected (Dense) cu 128 de neuroni, activare ReLU.
- **Stratul 2:** Dropout cu o rată de 0.2 (20% din conexiuni eliminate aleatoriu).
- **Stratul 3:** Fully Connected (Dense) cu 64 de neuroni, activare ReLU.
- **Stratul 4:** Dropout cu o rată de 0.2.
- **Stratul final:** Fully Connected (Dense) cu 10 neuroni (corespunzători celor 10 clase de ieșire), activare Softmax.

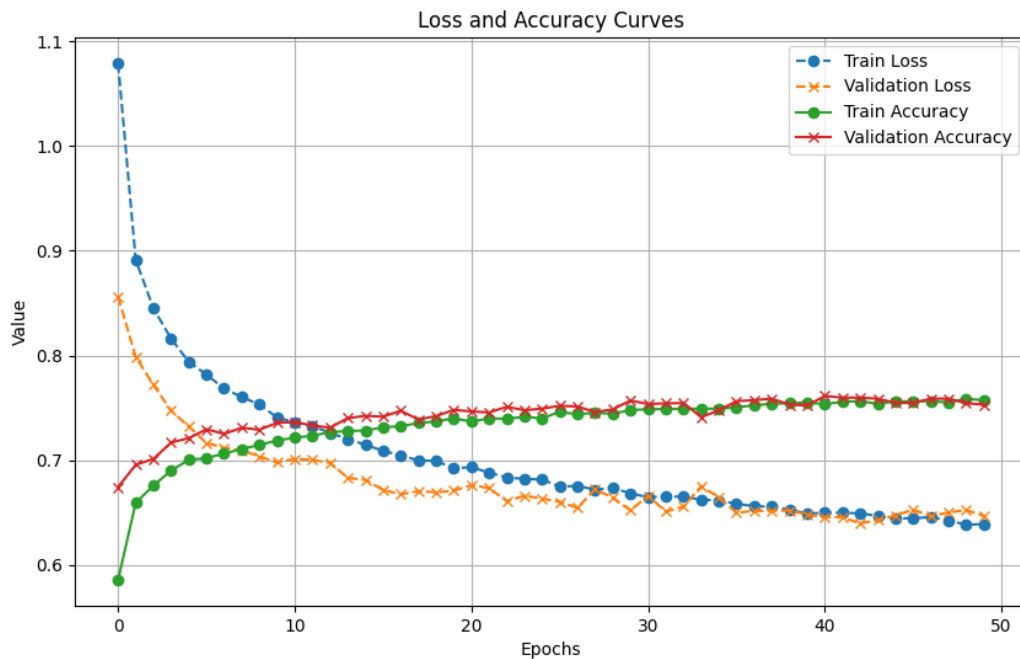
2. Funcțiile de activare utilizate:

- ReLU (Rectified Linear Unit) pentru straturile ascunse.
- Softmax pentru stratul final (utilizat pentru clasificare multi-clasă).

Caracteristicile procesului de antrenare

1. **Numărul de epoci de antrenare:** - modelul a fost antrenat timp de **50 de epoci**.
2. **Metodele de regularizare alese:** - s-a utilizat **Dropout** în straturile ascunse pentru a preveni overfitting, cu o rată de 20%.
3. **Funcția de eroare utilizată:** - **sparse_categorical_crossentropy**, utilizată pentru probleme de clasificare multi-clasă, unde etichetele sunt codificate ca valori întregi (nu one-hot).
4. **Dimensiunea batch-ului:** - **64** (datele sunt procesate în loturi de 64 de imagini).
5. **Optimizatorul folosit:** - **Adam** (Adaptive Moment Estimation) cu o rată de învățare de **0.001**.

Grafic



Curba "Train Loss" (albastru cu puncte):

- Scade constant în timpul antrenării, ceea ce indică faptul că modelul se ajustează la datele de antrenament.
- Pierdere se stabilizează după aproximativ 20 de epoci, ceea ce sugerează că modelul converge.

Curba "Validation Loss" (portocaliu cu X-uri):

- Inițial scade rapid, ceea ce indică faptul că modelul îmbunătățește performanța pe setul de validare.
- După aproximativ 10-15 epoci, începe să se stabilizeze

Curba "Train Accuracy" (verde cu puncte):

- Crește constant pe parcursul antrenării, atingând o valoare maximă după aproximativ 20-30 de epoci.
- Acuratețea mare pe setul de antrenament indică faptul că modelul este bine ajustat la datele de antrenament.

Curba "Validation Accuracy" (roșu cu X-uri):

- Crește rapid în primele epoci, apoi se stabilizează, rămânând aproape constantă după 15 epoci.
- Acuratețea pe setul de validare este mai mică decât cea pe setul de antrenament, sugerând din nou o ușoară tendință de overfitting.

```

Epoch 47/50
750/750 - 2s - loss: 0.6441 - accuracy: 0.7556 - val_loss: 0.6540 - val_accuracy: 0.7563
Epoch 48/50
750/750 - 2s - loss: 0.6414 - accuracy: 0.7546 - val_loss: 0.6512 - val_accuracy: 0.7574
Epoch 49/50
750/750 - 3s - loss: 0.6441 - accuracy: 0.7554 - val_loss: 0.6444 - val_accuracy: 0.7588
Epoch 50/50
750/750 - 2s - loss: 0.6420 - accuracy: 0.7578 - val_loss: 0.6462 - val_accuracy: 0.7567
313/313 [=====] - 1s 3ms/step - loss: 0.6746 - accuracy: 0.7471
Test Loss: 0.6745704412460327, Test Accuracy: 0.7470999956130981
Classification Report:

```

| | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0 | 0.72 | 0.73 | 0.72 | 1000 |
| 1 | 0.88 | 0.88 | 0.88 | 1000 |
| 2 | 0.63 | 0.71 | 0.67 | 1000 |
| 3 | 0.81 | 0.72 | 0.76 | 1000 |
| 4 | 0.62 | 0.70 | 0.66 | 1000 |
| 5 | 0.88 | 0.78 | 0.82 | 1000 |
| 6 | 0.58 | 0.47 | 0.52 | 1000 |
| 7 | 0.80 | 0.65 | 0.72 | 1000 |
| 8 | 0.93 | 0.94 | 0.93 | 1000 |
| 9 | 0.68 | 0.90 | 0.78 | 1000 |
| accuracy | | | 0.75 | 10000 |
| macro avg | 0.75 | 0.75 | 0.75 | 10000 |
| weighted avg | 0.75 | 0.75 | 0.75 | 10000 |

Comparare cu algoritmi din etapa 1

| | MLP | Logistic Regression | SVM | Random Forest | GradientBoosted |
|----------|-------|---------------------|--------|---------------|-----------------|
| Accuracy | 74.7% | 69.28% | 77.93% | 78.17% | 78.66% |

Deși există algoritmi pentru care am obținut o acuratețe mai bună, pentru MLP timpul de rulare a fost considerabil mai mic.

2. Arhitectura de tip MLP direct peste imagini


Arhitectura rețelei:

- **Straturi:**
 - Stratul de intrare are 512 neuroni, corespunzând dimensiunii imaginii liniarizate.
 - Rețeaua are trei straturi ascunse cu numărul de neuroni în ordine descrescătoare: 512 → 256 → 128.
 - Stratul de ieșire are 10 neuroni (corespunzând numărului de clase).
- **Funcțiile de activare:**
 - ReLU (Rectified Linear Unit): folosită pentru straturile ascunse, ceea ce permite rețelei să modeleze relații complexe.
 - Softmax: pentru stratul de ieșire, utilizată pentru a genera probabilități pe clase.
- **Regularizare:**

- Dropout: este aplicat cu rate de 30% la primele două straturi ascunse și cu 20% la al treilea strat, pentru a preveni overfitting-ul.

Caracteristicile procesului de antrenare:

- **Numărul de epoci:** 50 epoci, ceea ce oferă suficiente iterații pentru a observa convergența modelului.
- **Dimensiunea batch-ului:** 64, un compromis între utilizarea eficientă a memoriei și stabilitatea gradientului.
- **Optimizator:** Adam (Adaptive Moment Estimation): un algoritm optimizat pentru învățarea gradientului, care ajustează dinamic ratele de învățare.
- **Funcția de pierdere:** sparse_categorical_crossentropy, potrivită pentru problemele de clasificare multi-clasă.



Train Loss (albastru):

- Scade constant pe parcursul epocilor, ceea ce indică faptul că modelul se adaptează bine datelor de antrenament.

Validation Loss (portocaliu):

- Inițial, Validation Loss scade, ceea ce indică o îmbunătățire a generalizării, începând de la aproximativ epoca 20-25, Validation Loss începe să crească ușor

Train Accuracy (verde):

- Crește rapid în primele epoci, ajungând aproape de 100% (aproximativ 0.95-0.97), ceea ce indică o potrivire excelentă pe setul de antrenament.

Validation Accuracy (roșu):

- Crește semnificativ în primele epoci, atingând un platou în jurul valorii de 0.85-0.88.

```

Epoch 47/50
750/750 - 7s - loss: 0.1654 - accuracy: 0.9406 - val_loss: 0.3870 - val_accuracy: 0.8957
Epoch 48/50
750/750 - 7s - loss: 0.1700 - accuracy: 0.9403 - val_loss: 0.3756 - val_accuracy: 0.8966
Epoch 49/50
750/750 - 7s - loss: 0.1637 - accuracy: 0.9432 - val_loss: 0.3879 - val_accuracy: 0.8967
Epoch 50/50
750/750 - 7s - loss: 0.1596 - accuracy: 0.9421 - val_loss: 0.3728 - val_accuracy: 0.8942
313/313 [=====] - 1s 4ms/step - loss: 0.4054 - accuracy: 0.8886
Test Loss (Images): 0.4054414629936218, Test Accuracy (Images): 0.8885999917984009
Classification Report (Images):

```

| | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0 | 0.89 | 0.78 | 0.83 | 1000 |
| 1 | 0.99 | 0.98 | 0.99 | 1000 |
| 2 | 0.76 | 0.86 | 0.81 | 1000 |
| 3 | 0.91 | 0.90 | 0.90 | 1000 |
| 4 | 0.84 | 0.81 | 0.82 | 1000 |
| 5 | 0.96 | 0.96 | 0.96 | 1000 |
| 6 | 0.72 | 0.73 | 0.72 | 1000 |
| 7 | 0.91 | 0.97 | 0.94 | 1000 |
| 8 | 0.97 | 0.97 | 0.97 | 1000 |
| 9 | 0.97 | 0.92 | 0.95 | 1000 |
| accuracy | | | 0.89 | 10000 |
| macro avg | 0.89 | 0.89 | 0.89 | 10000 |
| weighted avg | 0.89 | 0.89 | 0.89 | 10000 |

3. Arhitectura de tip convoluțional

Arhitectura rețelei:

- **Straturi convoluționale:**
 - **Primul strat:** Convoluție cu 32 de filtre, dimensiune kernel $3 \times 3 \times 3$, activare ReLU.
 - **Al doilea strat:** Convoluție cu 64 de filtre, dimensiune kernel $3 \times 3 \times 3$, activare ReLU.
 - **Al treilea strat:** Convoluție cu 128 de filtre, dimensiune kernel $3 \times 3 \times 3$, activare ReLU.
- **Batch Normalization:**
 - După fiecare strat convoluțional, se normalizează activările pentru a accelera antrenarea și a stabili procesul de optimizare.
- **Pooling:**
 - **MaxPooling:** După fiecare strat convoluțional, pooling cu dimensiunea $2 \times 2 \times 2$ pentru reducerea dimensiunii spațiale.
- **Global Average Pooling:**
 - Reduce ieșirile convoluționale într-un vector de caracteristici, agregând valorile pe întreaga imagine.
- **Straturi dense (Fully Connected):**

- **Primul strat:** 256 neuroni, activare ReLU, regularizare L2 ($\lambda=0.01$ \lambda = 0.01 $\lambda=0.01$).
- **Dropout:** 50% pentru prevenirea overfitting-ului.
- **Al doilea strat:** 128 neuroni, activare ReLU, regularizare L2 ($\lambda=0.01$ \lambda = 0.01 $\lambda=0.01$).
- **Dropout:** 40%.
- **Strat de ieșire:** 10 neuroni (corespunzând claselor), activare softmax pentru clasificare probabilistică.

Caracteristicile procesului de antrenare:

1. Numărul de epoci:

- 50 epoci pentru ambele variante (fără augmentări și cu augmentări).
- Numărul suficient pentru convergență și evaluarea efectelor augmentării.

2. Metodele de regularizare alese:

- Regularizare L2 ($\lambda=0.01$ \lambda = 0.01 $\lambda=0.01$) aplicată pe straturile dense pentru penalizarea greutăților mari.
- Dropout:
 - 50% pentru primul strat dense.
 - 40% pentru al doilea strat dense.

3. Funcția de eroare utilizată:

- `sparse_categorical_crossentropy`: Se utilizează pentru problemele de clasificare multiclasă.


4. Dimensiunea batch-ului:

- 128 imagini/batch: ales pentru a găsi un echilibru între utilizarea eficientă a memoriei GPU și stabilitatea optimizării.

5. Optimizatorul folosit:

- **Fără augmentări:** RMSprop cu rată de învățare 0.0005:
 - Bun pentru probleme non-staționare și reducerea oscilării în minimizarea funcției de cost.
- **Cu augmentări:** Adam cu rată de învățare 0.0005:
 - Bun pentru ajustarea dinamică a ratelor de învățare și convergență rapidă în prezența datelor augmentate.

Grafice



Fără augmentări (No Aug)- ACCURACY

- **Train Accuracy (No Aug):** Observăm o creștere constantă a acurateței pe setul de antrenare, ceea ce indică faptul că modelul învață bine din datele de antrenare.
- **Validation Accuracy (No Aug):** Acuratețea pe setul de validare crește la început, dar se stabilizează și nu atinge valori foarte mari comparativ cu setul de antrenare.

Cu augmentări (With Aug):

- **Train Accuracy (With Aug):** Acuratețea pe setul de antrenare este relativ mai mică, iar variațiile sunt mai mari din cauza augmentărilor.

- **Validation Accuracy (With Aug):** Acuratețea pe setul de validare este extrem de fluctuantă, ceea ce sugerează instabilitate în procesul de antrenare.

Fără augmentări (No Aug)- LOSS

- **Train Loss (No Aug):** Pierderea pe setul de antrenare scade constant, indicând o convergență clară a modelului.
- **Validation Loss (No Aug):** Pierderea pe setul de validare este relativ stabilă, ceea ce indică faptul că modelul generalizează relativ bine, deși cu o performanță mai modestă.

Cu augmentări (With Aug):

- **Train Loss (With Aug):** Pierderea pe setul de antrenare are variații semnificative, ceea ce reflectă impactul augmentărilor și complexitatea sarcinii. Modelul nu converge bine.
- **Validation Loss (With Aug):** Pierderea pe setul de validare are fluctuații extreme și valori foarte mari.

| Classification Report (CNN No Aug): | | | | |
|-------------------------------------|-----------|--------|----------|---------|
| | precision | recall | f1-score | support |
| 0 | 0.11 | 0.99 | 0.20 | 1000 |
| 1 | 0.00 | 0.00 | 0.00 | 1000 |
| 2 | 0.69 | 0.10 | 0.18 | 1000 |
| 3 | 0.08 | 0.00 | 0.01 | 1000 |
| 4 | 0.00 | 0.00 | 0.00 | 1000 |
| 5 | 0.00 | 0.00 | 0.00 | 1000 |
| 6 | 0.00 | 0.00 | 0.00 | 1000 |
| 7 | 0.00 | 0.00 | 0.00 | 1000 |
| 8 | 0.53 | 0.48 | 0.51 | 1000 |
| 9 | 0.00 | 0.00 | 0.00 | 1000 |
| accuracy | | | 0.16 | 10000 |
| macro avg | 0.14 | 0.16 | 0.09 | 10000 |
| weighted avg | 0.14 | 0.16 | 0.09 | 10000 |

| Classification Report (CNN With Aug): | | | | |
|---------------------------------------|-----------|--------|----------|---------|
| | precision | recall | f1-score | support |
| 0 | 0.00 | 0.00 | 0.00 | 1000 |
| 1 | 0.32 | 0.56 | 0.40 | 1000 |
| 2 | 0.12 | 0.67 | 0.21 | 1000 |
| 3 | 0.00 | 0.00 | 0.00 | 1000 |
| 4 | 0.00 | 0.00 | 0.00 | 1000 |
| 5 | 0.29 | 0.74 | 0.42 | 1000 |
| 6 | 0.00 | 0.00 | 0.00 | 1000 |
| 7 | 0.00 | 0.00 | 0.00 | 1000 |
| 8 | 0.00 | 0.00 | 0.00 | 1000 |
| 9 | 0.00 | 0.00 | 0.00 | 1000 |
| accuracy | | | 0.20 | 10000 |
| macro avg | 0.10 | 0.20 | 0.11 | 10000 |
| weighted avg | 0.10 | 0.20 | 0.11 | 10000 |

```
Epoch 46/50
375/375 - 72s - loss: 0.1643 - accuracy: 0.9663 - val_loss: 19.2316 - val_accuracy: 0.2857
Epoch 47/50
375/375 - 81s - loss: 0.1613 - accuracy: 0.9672 - val_loss: 41.0465 - val_accuracy: 0.1140
Epoch 48/50
375/375 - 86s - loss: 0.1561 - accuracy: 0.9692 - val_loss: 18.3963 - val_accuracy: 0.1601
Epoch 49/50
375/375 - 96s - loss: 0.1536 - accuracy: 0.9681 - val_loss: 14.4796 - val_accuracy: 0.1367
Epoch 50/50
375/375 - 118s - loss: 0.1501 - accuracy: 0.9699 - val_loss: 26.6304 - val_accuracy: 0.1617
313/313 [=====] - 15s 46ms/step - loss: 26.7370 - accuracy: 0.1585
Test Loss (No Augmentations): 26.736980438232422, Test Accuracy (No Augmentations): 0.1585000083446503
```

```
Epoch 47/50
469/469 - 45s - loss: 0.8597 - accuracy: 0.7200 - val_loss: 1077.7950 - val_accuracy: 0.3062
Epoch 48/50
469/469 - 45s - loss: 0.8571 - accuracy: 0.7213 - val_loss: 1059.2122 - val_accuracy: 0.2647
Epoch 49/50
469/469 - 42s - loss: 0.8733 - accuracy: 0.7148 - val_loss: 1368.0248 - val_accuracy: 0.2749
Epoch 50/50
469/469 - 41s - loss: 0.8935 - accuracy: 0.7067 - val_loss: 2364.2629 - val_accuracy: 0.2004
313/313 [=====] - 3s 8ms/step - loss: 2364.2629 - accuracy: 0.2004
Test Loss (With Augmentations): 2364.262939453125, Test Accuracy (With Augmentations): 0.2003999948501587
```


4. Utilizarea unei proceduri de finetuning peste arhitectura ResNet-18

Arhitectura rețelei:

1. Baza modelului:

- Modelul este pre-antrenat pe setul ImageNet. Acest lucru oferă un avantaj în extragerea caracteristicilor relevante, deoarece rețeaua are deja cunoștințe generalizate despre imagini.
- Straturile convoluționale din model sunt inițial înghetate (`base_model.trainable = False`) pentru a preveni modificarea parametrilor pre-antrenați.

2. Adăugarea straturilor personalizate:

- Global Average Pooling 2D (GAP): Rezumă caracteristicile extrase de straturile convoluționale într-un vector compact.
- Fully Connected Layers:
 - Un strat dens cu 256 neuroni și activare relu pentru procesarea caracteristicilor.
 - Un strat final de 10 neuroni cu activare softmax pentru clasificare în cele 10 clase din Fashion-MNIST.
- Regularizare:
 - Un strat de Dropout cu rată de 0.5 pentru a reduce overfitting-ul în timpul antrenării.

Procesul de antrenare:

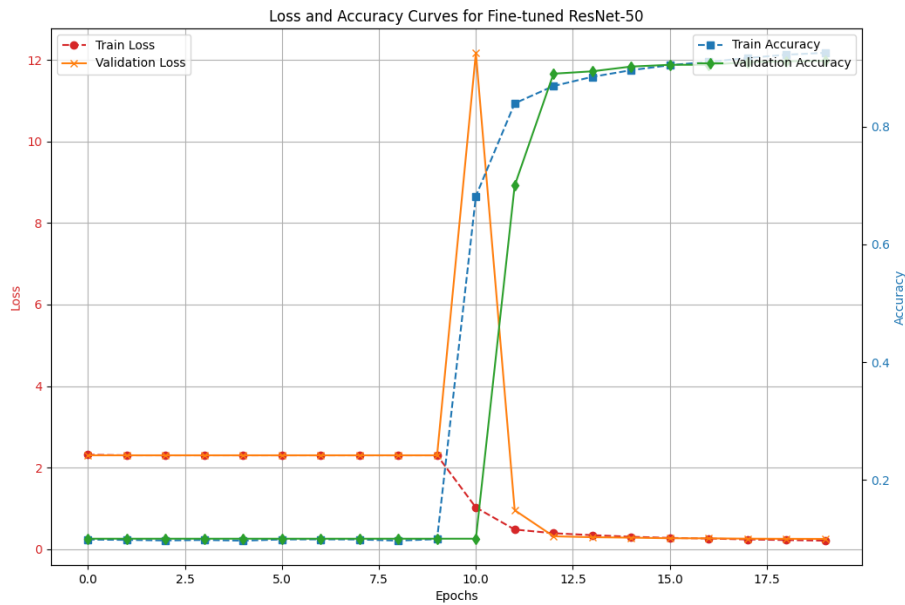
1. Fază 1: Antrenarea doar a straturilor personalizate:

- Înghetarea straturilor pre-antrenate: Doar straturile personalizate sunt antrenate.
- Optimizator: SGD cu rata de învățare 0.001 și momentum 0.9 pentru stabilitate și o convergență mai rapidă.
- Funcția de pierdere: `sparse_categorical_crossentropy`, adecvată pentru clasificare multi-clasă.
- Dimensiunea batch-ului: 64.
- Numărul de epoci: 10.

2. Fază 2: Fine-tuning al straturilor pre-antrenate:

- Straturile sunt deblocate (`base_model.trainable = True`), iar întregul model este antrenat pentru a ajusta fin parametrii.
- Rată de învățare mai mică: 0.0001, pentru a evita alterarea rapidă a parametrilor pre-antrenați.
- Numărul de epoci suplimentare: 10.

Grafice



1. Faza inițială (primele 10 epoci - straturi înghețate):

- Train Loss rămâne constantă, indicând antrenarea doar a straturilor noi (fully connected și dropout).
- Validation Loss crește progresiv, semnalând supraînvățare parțială.
- Train Accuracy crește lent, pe măsură ce straturile noi se ajustează.
- Validation Accuracy rămâne scăzută, sugerând că baza modelului nu este complet adaptată.

2. Faza de fine-tuning (straturi deblocate):

- Pierderile (Train și Validation Loss) scad dramatic, deoarece întregul model este ajustat. Validation Loss fluctuează la început, dar se stabilizează ulterior.
- Accuracy: Train Accuracy crește rapid (peste 90%), indicând un bun antrenament. Validation Accuracy urmează o traiectorie similară, demonstrând o generalizare bună după stabilizare.

```
Epoch 10/10
938/938 - 129s - loss: 2.3026 - accuracy: 0.0993 - val_loss: 2.3026 - val_accuracy: 0.1000
Epoch 1/10
938/938 - 2358s - loss: 1.0224 - accuracy: 0.6818 - val_loss: 12.1754 - val_accuracy: 0.1000
Epoch 2/10
938/938 - 2145s - loss: 0.4823 - accuracy: 0.8395 - val_loss: 0.9564 - val_accuracy: 0.6999
Epoch 3/10
938/938 - 2228s - loss: 0.3916 - accuracy: 0.8689 - val_loss: 0.3163 - val_accuracy: 0.8899
Epoch 4/10
938/938 - 2531s - loss: 0.3449 - accuracy: 0.8845 - val_loss: 0.2939 - val_accuracy: 0.8939
Epoch 5/10
938/938 - 2268s - loss: 0.3047 - accuracy: 0.8958 - val_loss: 0.2828 - val_accuracy: 0.9020
Epoch 6/10
938/938 - 2150s - loss: 0.2767 - accuracy: 0.9044 - val_loss: 0.2685 - val_accuracy: 0.9050
Epoch 7/10
938/938 - 2141s - loss: 0.2616 - accuracy: 0.9100 - val_loss: 0.2666 - val_accuracy: 0.9050
Epoch 8/10
938/938 - 2129s - loss: 0.2390 - accuracy: 0.9165 - val_loss: 0.2580 - val_accuracy: 0.9097
Epoch 9/10
938/938 - 2027s - loss: 0.2242 - accuracy: 0.9222 - val_loss: 0.2546 - val_accuracy: 0.9110
Epoch 10/10
938/938 - 2030s - loss: 0.2091 - accuracy: 0.9253 - val_loss: 0.2519 - val_accuracy: 0.9117
313/313 [=====] - 24s 76ms/step - loss: 0.2519 - accuracy: 0.9117
Test loss (ResNet-50 Fine-tuning): 0.25190359354019165, Test Accuracy (ResNet-50 Fine-tuning): 0.9117
```

| | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0 | 0.87 | 0.85 | 0.86 | 1000 |
| 1 | 1.00 | 0.97 | 0.98 | 1000 |
| 2 | 0.87 | 0.88 | 0.87 | 1000 |
| 3 | 0.90 | 0.90 | 0.90 | 1000 |
| 4 | 0.86 | 0.86 | 0.86 | 1000 |
| 5 | 0.97 | 0.98 | 0.98 | 1000 |
| 6 | 0.75 | 0.76 | 0.75 | 1000 |
| 7 | 0.96 | 0.96 | 0.96 | 1000 |
| 8 | 0.98 | 0.98 | 0.98 | 1000 |
| 9 | 0.97 | 0.96 | 0.96 | 1000 |
| accuracy | | | 0.91 | 10000 |
| macro avg | 0.91 | 0.91 | 0.91 | 10000 |
| weighted avg | 0.91 | 0.91 | 0.91 | 10000 |

Acuratete : 91.17%

5. Raport de evaluare comparativ

| | MLP pe attribute extrase | MLP direct pe imagini | CNN | ResNet-18 |
|-----------|--------------------------|-----------------------|---------------|--------------|
| Accuracy | 74.7% | 88.85% | 15%-20% | 91.17% |
| Precision | 0.75 | 0.89 | 0.14-0.10 | 0.91 |
| F1-score | 0.75 | 0.89 | 0.09-0.11 | 0.91 |
| Timp | 3s/epoca | 7s/epoca | 1.5 min/epoca | 30 min/epoca |

Performanță:

- ResNet-18 este cel mai performant (91.17% acuratețe, 0.91 F1-score), dar cel mai lent (30 min/epocă).
- MLP pe imagini oferă un bun compromis între viteză (7s/epocă) și performanță (88.85% acuratețe, 0.89 F1-score).
- MLP pe attribute extrase este rapid (3s/epocă), dar mai puțin performant (74.7% acuratețe).
- CNN are performanțe foarte slabe (15%-20% acuratețe), fiind inefficient.

Concluzie:

- Alege ResNet-18 pentru performanță maximă.
- MLP pe imagini este o alternativă rapidă și eficientă.
- MLP pe attribute este bun pentru constrângeri de timp, dar cu rezultate mai slabe.
- CNN fără augmentări nu este recomandat.

FRUITS

1. MLP pe attributele extrase în etapa 1

Am selectat exact 128 de attribute:

Numarul de attribute selectate: 128

Arhitectura rețelei:

- **Numărul de straturi și numărul de neuroni:**
 - **Stratul 1:** Fully connected (256 neuroni, input de dimensiunea input_size - numărul de attribute).
 - **Stratul 2:** Fully connected (128 neuroni).
 - **Stratul 3:** Fully connected (numărul de clase, în cazul Fruits-360: 80).
- **Funcțiile de activare:**


- **ReLU** pentru primele două straturi ascunse.
- **Softmax** implicit în stratul final datorită folosirii CrossEntropyLoss.
- **Metode de regularizare:**
 - Două straturi de **Dropout** (0.3) pentru a preveni overfitting.

Caracteristicile procesului de antrenare:

- **Numărul de epoci:** 50 epoci.
- **Dimensiunea batch-ului:** 64.
- **Funcția de eroare:** CrossEntropyLoss (potrivită pentru clasificare multi-clasă).
- **Optimizatorul folosit:** Adam cu rată de învățare de 0.001 (potrivit pentru convergență rapidă și stabilitate).
- **Date utilizate:**
 - Seturile de antrenare și testare sunt procesate prin DataLoader pentru eficiență.

Antrenare:

- **Fluxul antrenării:**
 - Propagarea înainte prin cele 3 straturi fully connected.
 - Calcularea pierderii folosind CrossEntropyLoss.
 - Backpropagation și actualizarea parametrilor prin Adam.



Train Loss
(curba albastră): Se menține aproape constantă la o valoare foarte mică după primele câteva epoci, ceea ce indică faptul că modelul reușește să învețe eficient din setul de antrenare.

Validation Loss
(curba portocalie): Este foarte apropiată de

Train Loss pe parcursul antrenării, ceea ce sugerează că modelul nu prezintă suprapunere (overfitting) semnificativă și generalizează bine pe setul de validare.

Train Accuracy (curba verde): Crește rapid în primele 10-15 epoci, apoi se stabilizează aproape de o valoare ridicată, peste **80%**, ceea ce indică faptul că modelul a învățat bine caracteristicile relevante din datele de antrenare.

Validation Accuracy (curba roșie): Urmează o traiectorie similară cu Train Accuracy, atingând valori în jurul a **80%**, ceea ce sugerează o generalizare bună și o performanță solidă pe setul de validare.

```
Epoch [47/50] - Train Loss: 0.4712, Train Acc: 84.02%, Test Loss: 1.2843, Test Acc: 76.23%
Epoch [48/50] - Train Loss: 0.4660, Train Acc: 84.22%, Test Loss: 1.2968, Test Acc: 76.43%
Epoch [49/50] - Train Loss: 0.4608, Train Acc: 84.39%, Test Loss: 1.3298, Test Acc: 76.65%
Epoch [50/50] - Train Loss: 0.4675, Train Acc: 84.16%, Test Loss: 1.3641, Test Acc: 75.16%
Classification Report:
      precision    recall  f1-score   support

     0       0.64       1.00       0.78        157
     1       0.46       0.59       0.51        164
     2       0.64       0.37       0.47        148
     3       0.17       0.21       0.19        160
     4       0.81       0.99       0.90        164
     5       0.67       0.65       0.66        161
     6       0.60       0.77       0.67        164
     7       0.39       0.48       0.43        152
     8       0.76       0.65       0.70        164
     9       0.88       0.73       0.79        164
    10       0.57       0.36       0.44        144
    11       0.71       0.76       0.73        166
```

```

136      0.87      0.70      0.77      158
137      0.82      0.66      0.73      249
138      0.91      0.78      0.84      157
139      1.00      1.00      1.00       80
140      0.99      1.00      0.99       80

accuracy              0.75      23619
macro avg             0.76      0.76      0.75      23619
weighted avg          0.76      0.75      0.74      23619

Numărul de exemple corecte: 17753
Numărul de exemple greșite: 5866
```

Comparare cu algoritmi din etapa 1

| | MLP | Logistic Regression | SVM | Random Forest | GradientBoosted |
|----------|--------|---------------------|--------|---------------|-----------------|
| Accuracy | 75.16% | 92.65% | 98.23% | 97.05% | 97.23% |

La fel ca la setul de date anterior timpul de antrenare este mai mic la MLP decat la algoritmi din etapa 1.

2. Arhitectura de tip MLP direct peste imagini

Arhitectura rețelei:

1. Numărul de straturi și neuroni:

Stratul 1: Fully connected (input → 512 neuroni), activare ReLU, dropout (0.3).

Stratul 2: Fully connected (512 → 256 neuroni), activare ReLU, dropout (0.3).

Stratul 3: Fully connected (256 → numărul de clase, 80 în Fruits-360), fără activare suplimentară (folosirea stratului softmax implicit în funcția de pierdere).

2. **Funcțiile de activare:** ReLU (Rectified Linear Unit) după fiecare strat hidden.

3. **Regularizare:** Straturi Dropout cu o rată de 0.3 pentru a preveni supraantrenarea.

Caracteristicile procesului de antrenare:

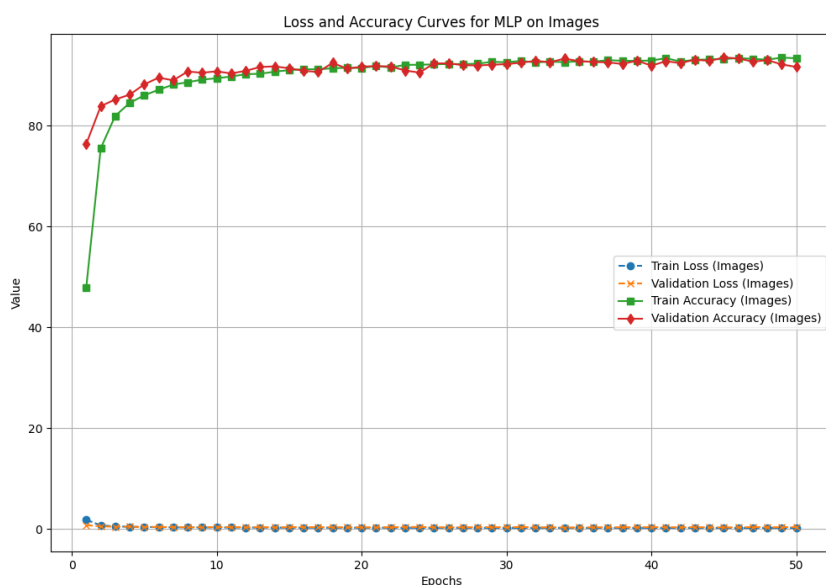
1. **Numărul de epoci:** 50 epoci.

2. **Metode de regularizare:**

- **Dropout:** Adăugat la fiecare strat hidden (0.3).
- **Normalizarea imaginilor:** Valorile pixelilor sunt scalate în intervalul [0, 1] prin împărțire la 255.

3. **Funcția de pierdere:** CrossEntropyLoss (potrivită pentru clasificare multi-clasă).
4. **Dimensiunea batch-ului:** Batch de 64 imagini.
5. **Optimizator:** Adam (Adaptive Moment Estimation) cu rata de învățare $lr=0.001$.

Grafic



supraantrenare.

Train Accuracy:

Acuratețea pe setul de antrenare crește rapid și atinge o valoare foarte mare (aproape 100%), indicând că modelul poate învăța aproape perfect din datele de antrenare.

Validation Accuracy:

Acuratețea pe setul de validare urmează îndeaproape acuratețea pe antrenare și se stabilizează la o valoare similară. Acest lucru sugerează că modelul are o capacitate excelentă de generalizare pe datele de test.

```
Epoch [46/50] - Train Loss: 0.2428, Train Acc: 92.88%, Test Loss: 0.3904, Test Acc: 91.58%
Epoch [47/50] - Train Loss: 0.2505, Train Acc: 92.77%, Test Loss: 0.3419, Test Acc: 92.02%
Epoch [48/50] - Train Loss: 0.2513, Train Acc: 92.69%, Test Loss: 0.3291, Test Acc: 92.76%
Epoch [49/50] - Train Loss: 0.2433, Train Acc: 92.86%, Test Loss: 0.3380, Test Acc: 93.12%
Epoch [50/50] - Train Loss: 0.2377, Train Acc: 93.20%, Test Loss: 0.3493, Test Acc: 92.60%
```

Classification Report (Images):

| | precision | recall | f1-score | support |
|---|-----------|--------|----------|---------|
| 0 | 0.85 | 1.00 | 0.92 | 157 |
| 1 | 0.91 | 0.72 | 0.80 | 164 |
| 2 | 1.00 | 1.00 | 1.00 | 148 |
| 3 | 0.94 | 0.90 | 0.92 | 160 |
| 4 | 0.98 | 1.00 | 0.99 | 164 |
| 5 | 0.91 | 0.99 | 0.95 | 161 |
| 6 | 0.98 | 1.00 | 0.99 | 164 |

| | | | | |
|-----|------|------|------|-----|
| 135 | 1.00 | 1.00 | 1.00 | 153 |
| 136 | 0.96 | 0.85 | 0.90 | 158 |
| 137 | 0.77 | 1.00 | 0.87 | 249 |
| 138 | 0.91 | 1.00 | 0.95 | 157 |
| 139 | 0.99 | 1.00 | 0.99 | 80 |
| 140 | 1.00 | 1.00 | 1.00 | 80 |

| | | | | |
|--------------|------|------|------|-------|
| accuracy | | | 0.93 | 23619 |
| macro avg | 0.93 | 0.92 | 0.92 | 23619 |
| weighted avg | 0.93 | 0.93 | 0.92 | 23619 |

3. Arhitectura de tip convoluțional

Arhitectura rețelei:


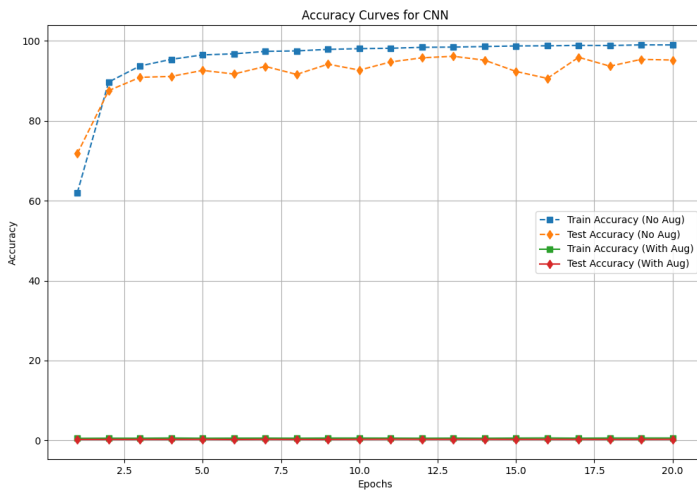
- Tipuri de straturi utilizate:

- **Convoluțional:**
 - Trei straturi convoluționale cu kernel-uri de dimensiune 3x3, urmate de straturi de Batch Normalization și activare ReLU.
 - Dimensiuni:
 - Primul strat: 3 -> 32 canale.
 - Al doilea strat: 32 -> 64 canale.
 - Al treilea strat: 64 -> 128 canale.
- **Pooling:**
 - Straturi de MaxPooling după fiecare strat convoluțional pentru reducerea dimensiunilor (pool-size = 2x2).
- **Global Pooling:**
 - Un strat de Global Average Pooling (AdaptiveAvgPool2d) pentru a reduce dimensiunile caracteristicilor extrase.
- **Fully Connected (Liniar):**
 - Primul strat: 128 intrări -> 256 neuroni, cu activare ReLU și Dropout (p=0.5).
 - Al doilea strat: 256 -> numărul de clase (e.g., 10 pentru clasificare).

Caracteristicile procesului de antrenare:

- **Numărul de epoci:** 20.
- **Dimensiunea batch-ului:** 64.
- **Funcția de eroare:** CrossEntropyLoss (potrivită pentru clasificarea multi-clasă).
- **Optimizator:** Adam, cu un learning rate de 0.001.
- **Metode de regularizare:**
 - Dropout în stratul Fully Connected (p=0.5).
 - Batch Normalization în straturile convoluționale pentru stabilizarea învățării.
- **Augmentări de date:**
 - Două scenarii:
 1. **Fără augmentări:** Imaginile sunt normalizate la [0.5, 0.5, 0.5].
 2. **Cu augmentări:** Se aplică:
 - RandomHorizontalFlip (flipping aleator pe orizontală),
 - RandomRotation (15 grade),
 - RandomResizedCrop (pentru recadrare și scalare).

Grafice



Train Accuracy (No Aug): Acuratețea pe setul de antrenare fără augmentări crește rapid și atinge aproape 100%.

Test Accuracy (No Aug): Acuratețea pe setul de test fără augmentări este mai mică decât cea de pe setul de antrenare, sugerând o posibilă lipsă de generalizare.

Train Accuracy (With Aug): Acuratețea pe setul de antrenare cu augmentări rămâne constantă și foarte mică. Acest lucru poate indica o problemă în implementarea augmentărilor sau în antrenarea modelului.

Test Accuracy (With Aug): Acuratețea pe setul de test cu augmentări este constantă și extrem de mică, sugerând că augmentările au fost implementate sau configurate greșit.

Train Loss (No Aug): Pierderea pe setul de antrenare fără augmentări scade progresiv, indicând că modelul învață eficient.

Test Loss (No Aug): Pierderea pe setul de test fără augmentări scade inițial, dar rămâne mai mare decât pierderea de antrenare.

Train Loss (With Aug) și Test Loss (With Aug): Pierderile sunt foarte mari și constante, ceea ce indică o problemă majoră, fie cu augmentările, fie cu arhitectura sau parametrii modelului.

```
Classification Report (CNN - No Augmentation):
```

| | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0 | 0.89 | 1.00 | 0.94 | 157 |
| 1 | 1.00 | 0.54 | 0.70 | 164 |
| 2 | 1.00 | 0.80 | 0.89 | 148 |
| 3 | 1.00 | 0.80 | 0.89 | 160 |
| 4 | 0.79 | 1.00 | 0.88 | 164 |
| 5 | 0.92 | 0.98 | 0.95 | 161 |
| 6 | 0.95 | 1.00 | 0.97 | 164 |
| 7 | 1.00 | 0.99 | 1.00 | 152 |
| 8 | 0.87 | 0.65 | 0.75 | 164 |
| 139 | 1.00 | 0.00 | 0.00 | 80 |
| 140 | 1.00 | 0.00 | 0.00 | 80 |
| accuracy | | | 0.01 | 23619 |
| macro avg | 0.96 | 0.01 | 0.00 | 23619 |
| weighted avg | 0.96 | 0.01 | 0.00 | 23619 |

```
Classification Report (CNN - With Augmentation):
```

| | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0 | 1.00 | 0.00 | 0.00 | 157 |
| 1 | 1.00 | 0.00 | 0.00 | 164 |
| 2 | 1.00 | 0.00 | 0.00 | 148 |
| 3 | 1.00 | 0.00 | 0.00 | 160 |
| 4 | 1.00 | 0.00 | 0.00 | 164 |
| 5 | 0.00 | 0.00 | 0.00 | 161 |
| 6 | 1.00 | 0.00 | 0.00 | 164 |
| 7 | 1.00 | 0.00 | 0.00 | 152 |
| 137 | 0.99 | 1.00 | 0.99 | 249 |
| 138 | 0.95 | 1.00 | 0.98 | 157 |
| 139 | 1.00 | 1.00 | 1.00 | 80 |
| 140 | 0.94 | 1.00 | 0.97 | 80 |
| accuracy | | | 0.95 | 23619 |
| macro avg | 0.96 | 0.95 | 0.95 | 23619 |
| weighted avg | 0.96 | 0.95 | 0.95 | 23619 |

4. Utilizarea unei proceduri de finetuning peste arhitectura ResNet-18

1. Arhitectura și pregătirea datelor

- **Transformarea datelor:**

- Imaginile sunt redimensionate la 32x32 și normalizate pentru a fi compatibile cu ResNet-18 pre-antrenat pe CIFAR-10.
- Seturile de antrenare și test sunt gestionate printr-un Dataset personalizat, care aplică transformări pe imagini (normalizare și conversie în tensor).

- **Modelul ResNet-18:**

- ResNet-18 este un model pre-antrenat, încărcat cu greutatea pentru ImageNet (folosind ResNet18_Weights.IMAGENET1K_V1).
- Stratul complet conectat (fc) al modelului este înlocuit cu un strat specific sarcinii curente, care clasifică în num_classes (numărul de clase din Fruits-360).

2. Procesul de antrenare

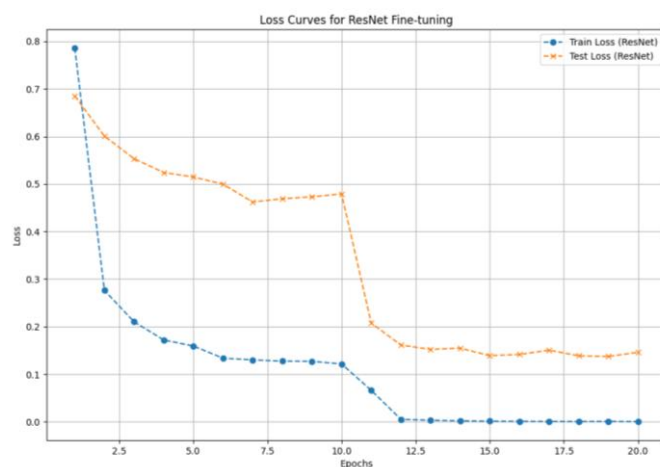

Etapa 1: Antrenare cu straturi înghețate (Frozen Layers)

- Scop: Adaptează stratul fully connected al modelului la setul de date Fruits-360.
- Configurație:
 - Straturile convoluționale ale modelului ResNet-18 sunt înghețate (param.requires_grad = False), antrenând doar stratul fc.
 - Optimizatorul este SGD cu rată de învățare de 0.01, momentul 0.9 și un scheduler care reduce rata de învățare la fiecare 5 epoci (StepLR).
 - Pierderea este măsurată cu funcția de eroare CrossEntropyLoss.
- Rezultat:
 - În această fază, performanța modelului pe setul de test este limitată, deoarece straturile convoluționale nu sunt ajustate pentru caracteristicile datelor Fruits-360.

Etapa 2: Fine-Tuning cu straturi deblocate

- Scop: Permite actualizarea tuturor straturilor ResNet-18 pentru a învăța reprezentări mai bune pentru Fruits-360.
- Configurație:
 - Toate straturile sunt deblocate (param.requires_grad = True).
 - Rata de învățare este redusă la 0.001 pentru a evita supraajustarea, iar optimizatorul rămâne SGD cu moment.
- Rezultat:
 - Performanța modelului crește semnificativ datorită ajustării întregii rețele.

Grafic



Train Accuracy:

- Creșterea rapidă în primele 5 epoci reflectă faptul că modelul învață rapid caracteristicile specifice datelor de antrenare.
- După epoca 10, acuratețea pe setul de antrenare atinge aproape 100%, ceea ce indică un model foarte bine ajustat pe datele de antrenare.

Test Accuracy:

- Acuratețea pe setul de testare urmează o tendință ascendentă și se stabilizează după aproximativ 10 epoci, atingând o valoare ridicată (~97.5%).
- Aceasta sugerează o generalizare bună a modelului asupra datelor noi.

Train Loss:

- Pierderea pe antrenare scade rapid în primele epoci și devine aproape constantă după epoca 10, indicând că modelul învață eficient reprezentările relevante pentru sarcină.
- După epoca 10, valoarea pierderii este extrem de mică, ceea ce corespunde acurateții foarte mari pe antrenare.

Test Loss:

- Pierderea pe setul de testare scade progresiv și devine stabilă după epoca 10.
- Nivelul mai ridicat al pierderii pe test în comparație cu antrenarea confirmă un mic grad de overfitting, dar pierderea rămâne într-un interval scăzut (sub 0.4), ceea ce indică o performanță bună.

Epoch [9/10] - Train Loss: 0.0010, Train Acc: 99.97%, Test Loss: 0.1375, Test Acc: 97.46%
 Epoch [10/10] - Train Loss: 0.0006, Train Acc: 99.99%, Test Loss: 0.1462, Test Acc: 97.60%
 Classification Report (ResNet):

| | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0 | 0.69 | 1.00 | 0.82 | 157 |
| 1 | 1.00 | 0.74 | 0.85 | 164 |
| 2 | 0.98 | 0.91 | 0.94 | 148 |
| 3 | 0.96 | 1.00 | 0.98 | 160 |
| 4 | 1.00 | 1.00 | 1.00 | 164 |
| 5 | 0.75 | 1.00 | 0.86 | 161 |
| 136 | 0.98 | 1.00 | 0.99 | 158 |
| 137 | 0.97 | 1.00 | 0.98 | 249 |
| 138 | 1.00 | 1.00 | 1.00 | 157 |
| 139 | 1.00 | 1.00 | 1.00 | 80 |
| 140 | 1.00 | 1.00 | 1.00 | 80 |
| accuracy | | | 0.98 | 23619 |
| macro avg | 0.98 | 0.98 | 0.98 | 23619 |
| weighted avg | 0.98 | 0.98 | 0.98 | 23619 |

5. Raport de evaluare comparativ

| | MLP pe attribute extrase | MLP direct pe imagini | CNN | ResNet-18 |
|-----------|--------------------------|-----------------------|---------------|--------------|
| Accuracy | 75.16% | 93.2% | 95%-5% | 97.5% |
| Precision | 0.76 | 0.93 | 0.96-0.10 | 0.98 |
| F1-score | 0.75 | 0.92 | 0.95-0.10 | 0.9 |
| Timp | 3s/epoca | 7s/epoca | 1.5 min/epoca | 30 min/epoca |

- ❑ **ResNet-18:** Cea mai bună acuratețe (97.5%) și scor F1 (0.98), dar cel mai lent (30 min/epocă).
- ❑ **CNN:** Performanță ridicată (95%) cu timp decent (1.5 min/epocă).
- ❑ **MLP pe imagini:** Bun compromis între performanță (93.2%) și timp (7 sec/epocă).
- ❑ **MLP pe attribute:** Performanță redusă (75.16%), dar cel mai rapid (3 sec/epocă).